

ENONCE DE PROJET ©

Matière : Fouille de données

Enseignants : Taoufik Ben Abdallah

Discipline : 2^{ème} année Génie Informatique

Tarek Ben Said

Année Universitaire : 2024-2025 / S1

Pour proposer des offres de contrats d'assurance habitation personnalisées, une compagnie d'assurance souhaite intégrer à son système un modèle capable de prédire la survenue d'un accident dans un bâtiment au cours de la période d'assurance. À cet effet, nous mettons à votre disposition le dataset ***train_insurance.csv***, contenant 5012 observations décrites par 12 attributs descripteurs et une variable cible, **claim**.

Voici une brève description des différentes variables :

- **Customer Id** : Le numéro d'identification du bénéficiaire
- **YearOfObservation** : L'année d'observation de l'état du bâtiment
- **Insured_Period** : La période d'assurance (1 : 1 ans, 0.5 : 6 mois)
- **Residential** : Le bâtiment est-il résidentiel ? (1 : oui, 0 : non)
- **Building_Painted** : Le bâtiment est-il peint ? (N : oui, V : non)
- **Building_Fenced** : Le bâtiment est-il clôturé ? (N : oui, V : non)
- **Garden** : Le bâtiment a-il un jardin ? (V : oui, O : non)
- **Settlement** : La zone du bâtiment. (R : zone rurale, U : zone urbain)
- **Building Dimension** : La taille du bâtiment en m²
- **Building_Type** : Le type de bâtiment ('Fire-resistive', 'Non-combustible', 'Ordinary', 'Wood-framed')
- **NumberOfWindows** : Le nombre de fenêtres du bâtiment (without dans le cas de 0 fenêtre)
- **Geo Code** : Le code géographique du bâtiment assuré
- **Claim** : La variable classe (oui si le bâtiment a au moins une réclamation pendant la période d'assurance, et non si le bâtiment n'a pas eu de réclamation pendant la période d'assurance)

Le **Tableau 1** montre un extrait du jeu de données ***train_insurance.csv***

Customer Id	YearOfObservation	Insured_Period	Residential	Building_Painted	Building_Fenced	Garden	Settlement	Building Dimension	Building_Type	NumberOfWindows	Geo_Code	Claim
H13501	2012	1.0	1	N	V	V	U	1240.0	Wood- framed	without	75117	non
H14962	2012	1.0	0	N	V	V	U	900.0	Non-combustible	without	62916	non
H17755	2013	1.0	1	V	N	O	R	4984.0	Non-combustible	4	31149	oui
H13369	2016	0.5	0	N	V	V	U	600.0	Wood-framed	without	6012	oui
H12988	2012	1.0	0	N	V	V	U	900.0	Non-combustible	without	57631	non
H3052	2016	0.5	0	N	V	V	U	2675.0	Ordinary	without	38185	non
:	:	:	:	:	:	:	:	:	:	:	:	:

Tableau 1 : Extrait du jeu de données *train_insurance.csv*

NB. Le fichier *test_insurance.csv* représente le jeu de données de test. Il comporte 2147 observations, et sera utilisé pour l'évaluation et la validation des modèles générés.

Travail à faire :

- 1/ Analyser et visualiser les données
- 2/ Nettoyer, **si nécessaire**, les données
- 3/ Sélectionner, **si nécessaire**, les descripteurs les plus discriminants
- 4/ Encoder les données et générer un ou plusieurs modèle(s) de prédiction en appliquant des **techniques d'apprentissage supervisée** (`DecisionTreeClassifier`, `SVC`, `MLPClassifier`, `GradientTreeBoosting`, `RandomForestClassifier`, etc.)
- 5/ Évaluer les performances du/des modèle(s) obtenu(s). **Interpréter les résultats**



Chaque groupe doit préparer une présentation PowerPoint comprenant trois parties :

1. **Contexte et motivation :** présenter le cadre du projet.
2. **Travail réalisé :** décrire les tâches effectuées, en détaillant les étapes suivies, les choix réalisés, et en interprétant les résultats obtenus à l'aide de diverses métriques et études comparatives.
3. **Conclusion et perspectives :** proposer des pistes d'amélioration pouvant être utiles pour optimiser les résultats obtenus.

La présentation ne doit pas dépasser 15 minutes, et il est recommandé de ne pas inclure de captures d'écran des codes.

En parallèle, les fichiers notebook (*.ipynb*) doivent être soigneusement préparés et déposés sur Moodle au plus tard 24 heures avant le jour de la soutenance.

Bon Travail ♣